Homework1

一、数据预处理和相关性分析

1.1 数据预处理

在训练之前，需要检查各列是否存在缺失值。实验结果表明，原始数据集中各变量均不存在缺失值，因此无需对缺失值进行额外填充处理。

```
缺失值处理后检查:
Cement                        0
Blast Furnace Slag            0
Fly Ash                       0
Water                         0
Superplasticizer              0
Coarse Aggregate              0
Fine Aggregate                0
Age                           0
Concrete compressive strength 0
dtype: int64
```

图 1 缺失值检查

1.2 绘制箱根图来看不同变量的分布

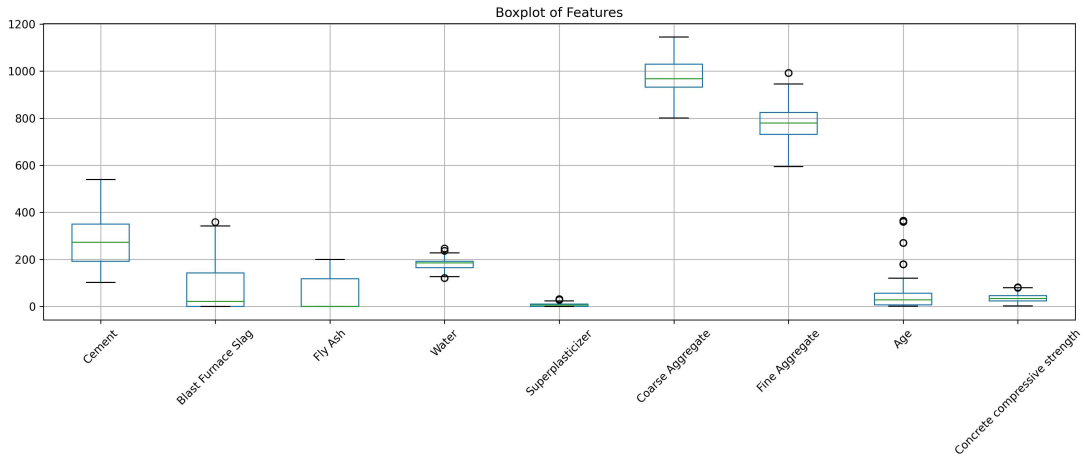

图 2 箱根图

箱根图显示了每个变量的数值范围、中位数、离散程度和异常值。该图可以看出

（1）不同特征的范围差异很大，coarse aggregate 大约在 800-1150，fine aggregate 大约在 600-1000，superplasticizer 大约只有几十，age 通常在较小范围，concrete compressive strength 大约在 0-80；

（2）部分特征存在离群点。例如 blast furnace slag, water 等。考虑到混凝土配比和龄期本身具有较强多样性，因此未对其直接剔除，而是通过标准化处理降低量

纲差异对模型训练的影响。

（3）部分变量分布偏斜。例如 fly ash, blast furnace slag 这类变量，箱体位置说明分布不太对称，意味着很多样本在较低值附近，也有部分样本拉高范围。这说明数据分布并不完全服从简单对称分布，后续线性模型可能无法完全刻画其复杂关系，神经网络可能更有优势。

1.3 绘制热力图分析变量相关性

图 2 表示所有变量两两之间的皮尔逊相关系数。红色越深表示正相关性越强，蓝色越深表示负相关性越强。该图可以看出输出变量 concrete compressive strength 与哪些输入更相关。根据最后一列：cement:0.50, superplastcizer:0.37, age:0.33 等内容可以看出，正相关性比较明显的特征是：水泥（cement），减水剂（superplasticizer）,龄期（age）。也就是说，这些变量增大时，抗压强度整体上倾向于增大。图 3 从线性相关的角度，也能看出比较重要的特征是 cement, superplasticizer, age, water。

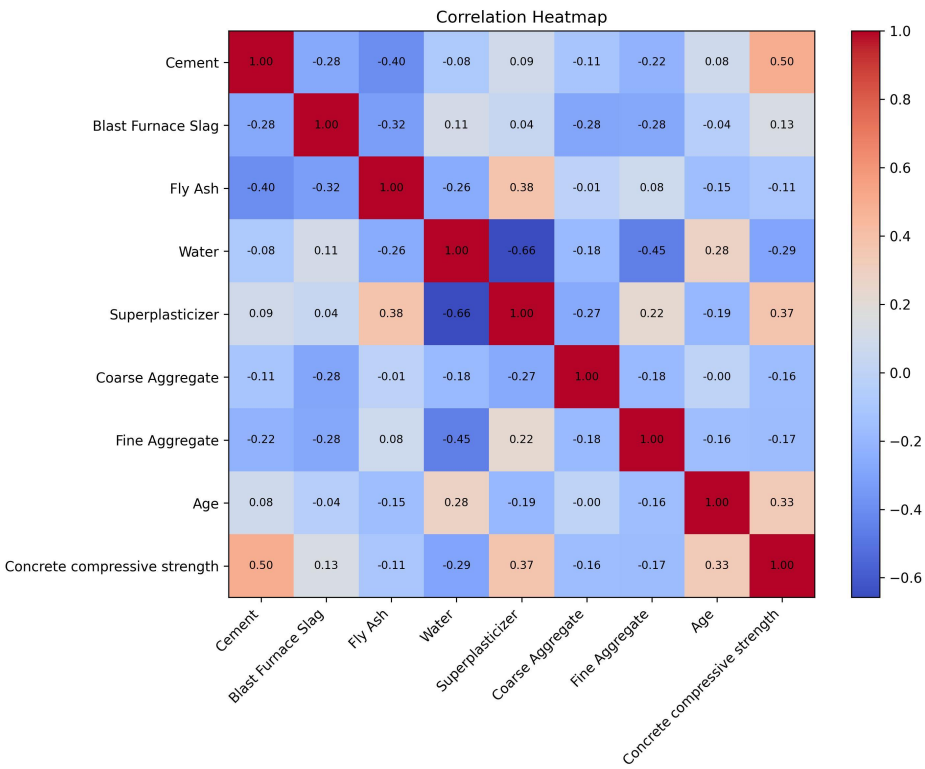

图 2 热力图

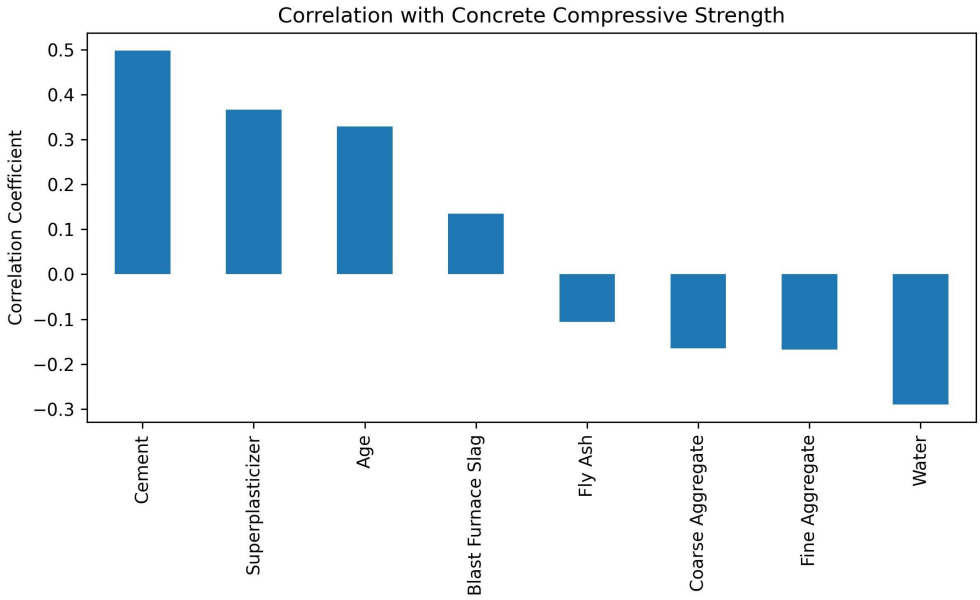

图 4 目标相关性条形图

为从原始输入变量中筛选出对混凝土抗压强度影响较显著的主特征，本文采用皮尔逊相关系数对各输入特征与输出变量之间的线性相关性进行计算。考虑到负相关特征同样可能对预测结果具有重要作用，因此以相关系数的绝对值作为筛选依据。设定相关性阈值为 0.20，当特征与目标变量的绝对相关系数大于或等于该阈值时，将其保留为主特征，否则予以剔除。根据计算结果，最终保留的主特征为 cement、water、superplasticizer 和 age，这些特征将作为后续回归模型的输入。

生成的 feature_selection_by_correlation.csv 里保存了相关性筛选结果，Feature 为特征名，Correlation 表示与目标的相关系数，Abolute Correlation 表示相关系数的绝对值。

```
Feature,Correlation,Absolute Correlation,Selected
Cement,0.4978319193241552,0.4978319193241552,True
Superplasticizer,0.3660788271885193,0.3660788271885193,True
Age,0.3288730007799875,0.3288730007799875,True
Water,-0.28963338498530294,0.28963338498530294,True
Fine Aggregate,-0.16724124729005901,0.16724124729005901,False
Coarse Aggregate,-0.16493461446011212,0.16493461446011212,False
Blast Furnace Slag,0.1348292614974053,0.1348292614974053,False
Fly Ash,-0.10575491629731448,0.10575491629731448,False
```

图 5 主特征筛选结果

1.4 数据标准化与数据集划分

由于 8 个输入特征的物理意义和取值范围差异较大，本文对输入特征采用标准化处理。具体而言，使用 StandardScaler 对训练集进行均值—方差标准化，再用相同参数对测试集进行变换。标准化后的特征均值接近 0，标准差接近 1，有助于提高神经网络训练过程的稳定性和收敛效率。此外，将数据集按照 8:2 的比例划分为训练集和测试集。

二、神经网络模型构建

由于混凝土抗压强度预测属于典型的回归问题，选择多层感知机神经网络作为预测模型。MLP 是一种前馈神经网络，能够通过多层线性变换与非线性激活函数学习输入与输出之间的复杂映射关系，适用于回归任务。

本作业构建的神经网络模型由输入层、两个隐藏层和输出层组成，具体结构如下：输入层：节点数等于筛选后主特征数，即 4；第一隐藏层：64 个神经元，激活函数为 ReLU；第二隐藏层：32 个神经元，激活函数为 ReLU；输出层：1 个神经元，用于预测。

采用 MSELoss 作为损失函数

三、实验结果

```
Epoch [1/300], Train Loss: 1559.4432
Epoch [20/300], Train Loss: 167.9407
Epoch [40/300], Train Loss: 93.2598
Epoch [60/300], Train Loss: 72.3503
Epoch [80/300], Train Loss: 66.1174
Epoch [100/300], Train Loss: 62.7726
Epoch [120/300], Train Loss: 59.7470
Epoch [140/300], Train Loss: 58.6021
Epoch [160/300], Train Loss: 56.2135
Epoch [180/300], Train Loss: 54.9397
Epoch [200/300], Train Loss: 53.3645
Epoch [220/300], Train Loss: 52.3147
Epoch [240/300], Train Loss: 51.3398
Epoch [260/300], Train Loss: 50.5099
Epoch [280/300], Train Loss: 49.9473
Epoch [300/300], Train Loss: 49.3771
```

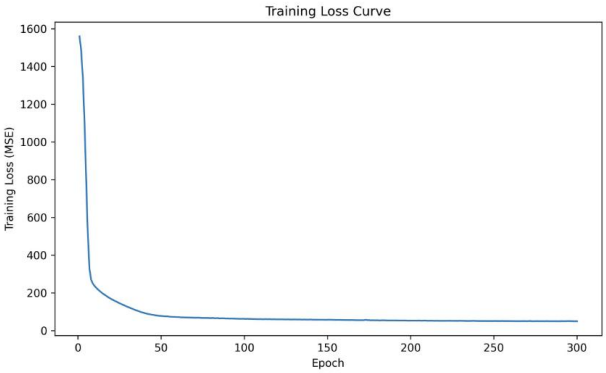

图 6 损失函数曲线

根据训练损失曲线可以看出，随着训练轮数的增加，模型损失整体呈下降趋势，并在后期逐渐趋于稳定。说明当前网络结构和学习率设置较为合理，没有出现明显的训练发散现象。

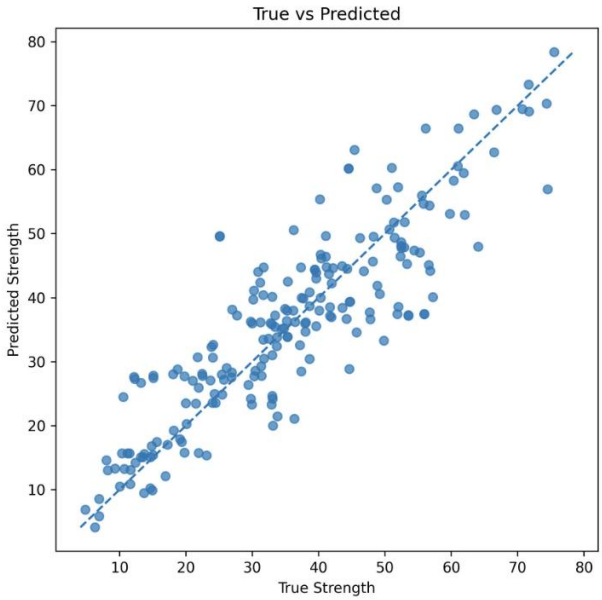

图 7 真实与预测值散点图

图 7 的散点为每个测试样本的（真实值，预测值）。从整体趋势来看，神经网络模型能够较好地捕捉主特征与混凝土抗压强度之间的非线性关系，因此具有一定的预测准确性，仍然有少量的点有较大偏离，说明模型在某些样本范围内仍存在一定误差。

模型在测试集上的具体评价指标如下：

```
Metric,Value
MSE,59.45245361328125
RMSE,7.710541719832741
MAE,5.805399417877197
R2,0.7692751884460449
```

图 8 测试评价指标

在测试集上，所构建的多层感知机回归模型取得了较好的预测效果，其中均方误差（MSE）为 59.45，均方根误差（RMSE）为 7.71 MPa，平均绝对误差（MAE）为 5.81 MPa，决定系数（R^2）为 0.7693。结果表明，该模型能够解释约 76.93% 的目标变量变化，说明神经网络已经较好地学习了混凝土抗压强度与输入特征之间的映射关系。同时，模型平均预测误差控制在一定范围内，具有较好的实用性，但在部分样本上仍存在一定偏差，后续仍可通过优化特征选择方法和网络结构进一步提高预测精度。