

基于 RNN 的 CNN/DailyMail 新闻文本摘要研究与实现

LSTM、BiLSTM 与 Attention 机制的对比实验

选题方向 自动文本摘要

数据集 CNN/DailyMail

主模型 BiLSTM + Attention

评价指标 ROUGE-1 / ROUGE-2 / ROUGE-L

实验规模 Train 5000 / Val 500 / Test 500

报告形式 HTML, 可直接打印为 PDF

摘要

本课程大作业围绕新闻自动摘要任务展开，选用 CNN/DailyMail 数据集，将新闻正文作为输入，将人工撰写的 highlights 作为生成目标。该任务不是机器翻译，而是同一语言内部的长文本压缩与信息重写问题，适合使用 Encoder-Decoder 序列生成框架进行建模。

实验实现了三类基于循环神经网络的摘要模型：LSTM Encoder-Decoder、BiLSTM Encoder-Decoder，以及作为主模型的 BiLSTM Encoder + Attention + LSTM Decoder。通过对比实验可以观察到，单纯使用最终隐状态的 Seq2Seq 模型难以处理长新闻文本，而 Attention 机制能够让 Decoder 在生成摘要时动态关注输入文章的不同位置，因此在 ROUGE 指标上取得更好的结果。

在 500 条测试样本上的实验结果表明，BiLSTM + Attention 的 ROUGE-1/ROUGE-2/ROUGE-L 为 6.86/0.59/5.96，高于 LSTM baseline 的 2.53/0.00/2.53 和 BiLSTM baseline 的 3.23/0.00/3.23。为了说明开源预训练摘要方法的效果，报告还加入 DistilBART-CNN-12-6 作为对比，其 ROUGE 达到 43.12/20.76/29.69，说明在真实新闻摘要任务中，大规模预训练 Transformer 仍明显优于从零训练的 RNN 模型。

关键词： 文本摘要；CNN/DailyMail；LSTM；BiLSTM；Attention；Seq2Seq；ROUGE；DistilBART

目录

第一章 选题背景与意义

第二章 任务定义与数据集

第三章 方法设计

第四章 实现流程

第五章 实验设置

第六章 实验结果

第七章 结果分析

第八章 总结与展望

附录 实验复现说明

第一章 选题背景与意义

1.1 选题背景

随着互联网新闻、社交媒体和知识库内容快速增长，用户每天面对的信息量远超人工阅读能力。新闻报道通常包含事件背景、采访细节、引用和延伸讨论，而用户往往希望快速获得核心事实。因此，自动文本摘要成为自然语言处理中的重要应用之一。

文本摘要的目标是将长文本压缩为短文本，同时尽量保留原文的关键信息。与文本分类、情感分析等判别任务不同，摘要任务要求模型生成一段自然语言文本，既要覆盖核心内容，又要保持语言连贯。这使得摘要任务更能体现序列建模、上下文表示和生成式建模的综合能力。

本课程主题涉及 RNN、LSTM 及相关序列模型。新闻摘要天然具有输入序列长、输出序列短、前后依赖明显的特点，因此适合作为 RNN 类模型的综合实践任务。通过该任务，可以比较单向 LSTM、双向 LSTM 和 Attention 机制在长文本生成中的不同作用。

1.2 研究意义

本实验的意义主要体现在三个方面。第一，从课程实践角度，完整实现了从数据准备、模型训练到自动评价的端到端流程。第二，从模型理解角度，通过多组实验观察到双向编码和 Attention 对长文本摘要的影响。第三，从工程对比角度，引入开源预训练模型 DistilBART 作为参考，使实验结果不仅停留在 RNN 内部比较，也能反映现代摘要系统的实际水平。

第二章 任务定义与数据集

2.1 任务定义

本实验任务为英文新闻文本摘要。给定一篇新闻正文 article，模型需要生成对应的摘要 highlights。输入和输出均为英文文本，因此该任务不是翻译任务，而是同一语言中的信息压缩与重写。

输入

CNN/DailyMail 新闻正文 article，通常较长，包含完整新闻叙述。

输出

人工摘要 highlights，长度较短，强调新闻核心事实。

目标

生成与参考摘要语义接近、表达连贯的短文本。

2.2 数据集说明

CNN/DailyMail 是自动摘要领域常用数据集，原始文本来自 CNN 和 DailyMail 新闻网页。每条样本主要包含新闻正文和摘要要点。本实验使用 HuggingFace 上的 **abisee/cnn_dailymail** 数据集，配置版本为 3.0.0。

字段	含义	在本实验中的作用
article	完整新闻正文	模型输入序列
highlights	人工撰写的新闻摘要	模型训练目标与评价参考

2.3 实验数据规模

完整 CNN/DailyMail 数据集规模较大，从零训练 RNN 模型耗时较长。考虑到课程作业的可复现性和训练成本，本实验使用固定子集完成训练、验证和测试。

数据划分	样本数	用途
Train	5000	训练 RNN 模型参数
Validation	500	选择验证集损失最低的 checkpoint
Test	500	计算最终 ROUGE 指标

2.4 数据预处理

实验使用 t5-small tokenizer 对输入正文和目标摘要进行分词。虽然主模型并不是 T5，但使用成熟 tokenizer 可以避免手写词表、低频词处理和特殊符号处理带来的额外误差。正文最大长度设置为 400 token，摘要最大长度设置为 100 token，超长文本截断，不足部分 padding。

截断长度会影响结果。RNN 模型只看到前 400 个 token，如果新闻关键信息出现在后文，模型无法利用这部分内容。这是 RNN 摘要效果偏低的重要原因之一。

第三章 方法设计

3.1 整体思路

本实验采用 Encoder-Decoder 框架。Encoder 读取新闻正文并生成上下文表示，Decoder 根据上下文表示逐步生成摘要。为了观察不同 RNN 结构的效果，实验设计了三组模型：基础 LSTM、BiLSTM 和 BiLSTM + Attention。

新闻正文

分词与截断

Encoder 编码

Decoder 生成

ROUGE 评价

3.2 LSTM Encoder-Decoder

LSTM Encoder-Decoder 是本实验的基础 baseline。Encoder 使用单向 LSTM 按顺序读取输入正文，将最终隐状态传给 Decoder。Decoder 再根据该隐状态逐词生成摘要。该方法结构简单，但存在明显瓶颈：整篇新闻需要被压缩到固定长度的最终隐状态中，长文本中的细节容易丢失。

3.3 BiLSTM Encoder-Decoder

BiLSTM 在 Encoder 端同时使用前向和后向 LSTM。前向 LSTM 捕获从文章开头到当前位置的信息，后向 LSTM 捕获从文章结尾反向到当前位置的信息。两者拼接后形成更完整的上下文表示。

相比单向 LSTM，BiLSTM 对输入文本的表示能力更强，但如果没有 Attention，Decoder 仍主要依赖最终状态，因此长文本瓶颈仍然存在。

3.4 BiLSTM + Attention 主模型

主模型在 BiLSTM Encoder 的基础上加入 Attention 机制。Attention 的作用是让 Decoder 在生成每一个摘要词时，根据当前生成状态选择性关注原文中的不同位置。这样模型不再只依赖 Encoder 的最后状态，而是能够动态读取整篇文章的局部信息。



从直观上看，摘要生成时不同词对应原文中的不同信息。例如生成新闻人物时应关注人物名称，生成事件结论时应关注新闻主句，生成地点或机构时应关注相关实体。Attention 正是为这种动态对齐提供了机制。

3.5 训练策略

训练过程中使用 teacher forcing，即 Decoder 下一步输入有一定概率使用真实目标词，而不是上一时间步模型预测词。本实验 teacher forcing ratio 设置为 0.5。损失函数使用忽略 padding token 的交叉熵损失，优化器为 Adam，并采用 gradient clipping 抑制 RNN 训练中的梯度爆炸。

3.6 开源预训练方法对比

为了回应“如何将 ROUGE 提升到二三十以上”的实验目标，报告加入了开源预训练摘要模型 DistilBART-CNN-12-6。该模型不是本课程作业的 RNN 主模型，而是作为现代开源方法参考。它已经在 CNN/DailyMail 上进行微调，并在评估时使用 beam search，因此能够取得远高于从零训练 RNN 的 ROUGE。

第四章 实现流程

4.1 项目流程

本项目实现了从数据到结果的完整流程。报告正文不展开大量代码，只说明各阶段功能。

阶段	主要内容	对应文件
数据准备	下载 CNN/DailyMail，完成分词、截断和 padding	data_prepare.py
数据加载	封装 Dataset 和 DataLoader，按 batch 提供训练数据	dataset.py
模型定义	实现 LSTM、BiLSTM、Attention 和 Seq2Seq 结构	model.py
模型训练	训练三种 RNN 模型，保存 best 和 last checkpoint	train.py
模型评价	生成摘要并计算 ROUGE 指标	evaluate.py
开源对比	调用 DistilBART 进行摘要生成和 ROUGE 评价	evaluate_pretrained.py

4.2 评价实现

评价阶段使用 ROUGE-1、ROUGE-2 和 ROUGE-L。当前运行环境未安装 rouge_score，因此程序使用本地 fallback 版本计算 ROUGE F1。该实现能够用于本实验内部模型对比；如果安装官方 rouge-score 包，程序会自动优先调用官方实现，绝对数值可能略有变化。

第五章 实验设置

5.1 RNN 模型超参数

参数	取值	说明
embedding_dim	256	词向量维度
hidden_dim	512	LSTM 隐状态维度
batch_size	8	受显存限制选择较小 batch
learning_rate	1e-3	Adam 优化器学习率
epochs	5	三种 RNN 模型均训练 5 轮
teacher_forcing_ratio	0.5	训练时使用真实目标词的概率
grad_clip	1.0	梯度裁剪阈值

5.2 模型规模

模型	可训练参数量	说明
LSTM Seq2Seq	36.58M	基础模型
BiLSTM Seq2Seq	38.68M	编码器改为双向结构
BiLSTM + Attention	82.66M	主模型，参数量最大，也更容易过拟合

5.3 DistilBART 对比设置

开源对比模型使用 sshleifer/distilbart-cnn-12-6。评估时输入最大长度为 1024，输出最大长度为 128，beam size 为 4，并设置 no_repeat_ngram_size 为 3 来减少重复生成。

第六章 实验结果

6.1 验证集损失

模型	checkpoint	Validation Loss
LSTM Seq2Seq	epoch 5	5.6677
BiLSTM Seq2Seq	epoch 5	5.6746
BiLSTM + Attention	best epoch 3	5.6785
BiLSTM + Attention	epoch 5	5.7864

从验证集损失看，LSTM baseline 略低于 BiLSTM + Attention 的 best checkpoint，但差距只有约 0.01。该结果不能直接说明 LSTM 摘要质量更好，因为 loss 衡量的是 teacher forcing 条件下逐 token 预测误差，而 ROUGE 衡量的是完整生成摘要与参考摘要的重合程度。

6.2 ROUGE 指标

模型	ROUGE-1	ROUGE-2	ROUGE-L	定位
LSTM Seq2Seq	2.53	0.00	2.53	基础 baseline
BiLSTM Seq2Seq	3.23	0.00	3.23	验证双向编码
BiLSTM + Attention	6.86	0.59	5.96	RNN 主模型
DistilBART-CNN-12-6	43.12	20.76	29.69	开源预训练模型对比

在 RNN 模型内部，BiLSTM + Attention 的 ROUGE 明显高于两个 baseline，说明 Attention 对长文本摘要有实际帮助。DistilBART 达到 40/20/30 左右，说明开源预训练模型能够稳定把 ROUGE 提升到二三十以上。

6.3 生成样例

下面选取同一条测试样本，对比 RNN 主模型与 DistilBART 的生成结果。为便于阅读，原文只展示开头片段。

原文片段

(CNN) I see signs of a revolution everywhere. I see it in the op-ed pages of the newspapers, and on the state ballots in nearly half the country...

参考摘要

CNN's Dr. Sanjay Gupta says we should legalize medical marijuana now. He says he knows how easy it is to do nothing "because I did nothing for too long".

RNN 主模型生成

The:,,,,,, . . . a a a . . . a . . . ,,,,,,

DistilBART 生成

John Sutter: I see signs of a medical marijuana revolution everywhere in the U.S. He says it's burning white hot among young people, but also shows up among parents and grandparents.

第七章 结果分析

7.1 为什么 Attention 有提升

LSTM 和 BiLSTM baseline 都需要将输入新闻压缩到有限隐状态中。对于短句任务，这种方式可能足够；但 CNN/DailyMail 的 article 很长，摘要又需要覆盖人物、事件、地点和结论等多个信息点，单个最终状态难以完整保存所有细节。Attention 允许 Decoder 在每个生成步重新选择关注的原文位置，因此能更好地处理长文本输入。

7.2 为什么 loss 最低不一定 ROUGE 最高

本实验中 LSTM 的 validation loss 略低，但 ROUGE 明显低于 BiLSTM + Attention。原因是 validation loss 在 teacher forcing 条件下计算，模型每一步都能看到真实前文；而测试时模型需要依赖自己已经生成的内容，一旦前面生成错误，后续错误会累积。因此，摘要任务不能只用 loss 判断好坏，最终仍应结合 ROUGE 和生成样例评价。

7.3 RNN 主模型效果偏低的原因

1. 训练数据只有 5000 条，而从零训练生成模型通常需要更多样本。
2. 输入长度截断为 400 token，新闻后半部分信息可能被丢弃。
3. 普通 Seq2Seq 缺少 pointer/copy mechanism，难以复制新闻中的人名、地名和机构名。
4. RNN 解码使用 greedy decoding，没有 beam search 和重复惩罚。
5. 模型缺少 coverage mechanism，因此容易出现重复生成和标点异常。

7.4 开源方法为什么能达到二三十以上

DistilBART 的优势不是单一超参数带来的，而是预训练、任务微调、Transformer 架构和 beam search 共同作用的结果。它在大规模语料上学习过语言建模能力，又针对 CNN/DailyMail 摘要任务进行过 fine-tuning，因此即使在同样的 500 条测试子集上，也能显著超过从零训练的 RNN。

第八章 总结与展望

8.1 总结

本课程大作业完成了 CNN/DailyMail 新闻摘要任务的完整实现与实验分析。实验表明，在 RNN 系列模型中，BiLSTM + Attention 的效果最好，说明双向编码和注意力机制能够提升长文本摘要质量。虽然主模型 ROUGE 绝对值不高，但其相对 baseline 的提升趋势清晰，符合模型设计预期。

同时，DistilBART 对比实验显示，开源预训练摘要模型能够在同一测试子集上达到 ROUGE-1 43.12、ROUGE-2 20.76、ROUGE-L 29.69。该结果说明，如果目标是实际应用效果，预训练 Transformer 是更合适的选择；如果目标是理解 RNN 序列生成机制，BiLSTM + Attention 仍然是有教学价值的主模型。

8.2 后续改进方向

1. 扩大训练集规模，使用完整 CNN/DailyMail 训练集训练更久。
2. 为 RNN Decoder 加入 beam search，提高推理阶段生成质量。
3. 引入 pointer-generator 机制，提高实体和关键词复制能力。
4. 引入 coverage mechanism，减少重复生成。
5. 尝试微调 T5、BART 或 PEGASUS，与 RNN 模型做更系统对比。

附录：实验复现说明

为保持报告正文的可读性，命令只放在附录中。实际运行时进入项目目录后执行即可。

```
cd /data/nHome/wangyifan/homework/RNN/cnn_dm_summary
```

```
python data_prepare.py --train_size 5000 --val_size 500 --test_size 500 --max_article_len 400 --max_summary_len 100 --output_dir data/processed
```

```
python train.py --model_type bilstm_attention --processed_dir data/processed --batch_size 8 --epochs 5 --output_dir checkpoints/bilstm_attention --device cuda:0
```

```
python evaluate.py --checkpoint checkpoints/bilstm_attention/best.pt --test_size 500 --batch_size 8 --device cuda:0
```

```
python evaluate_pretrained.py --model_name sshleifer/distilbart-cnn-12-6 --test_size 500 --batch_size 8 --device cuda:0 --fp16 --output_jsonl checkpoints/distilbart_cnn_12_6/test_predictions.jsonl --output_metrics checkpoints/distilbart_cnn_12_6/test_rouge.json
```

参考资料

1. CNN/DailyMail dataset repository: <https://github.com/abisee/cnn-dailymail>
2. HuggingFace abisee/cnn_dailymail dataset: https://huggingface.co/datasets/abisee/cnn_dailymail
3. DistilBART CNN/DailyMail model card: <https://huggingface.co/sshleifer/distilbart-cnn-12-6>
4. BART large CNN/DailyMail model card: <https://huggingface.co/facebook/bart-large-cnn>
5. Lewis et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. <https://arxiv.org/abs/1910.13461>